

Sürüm tarihi: 25/05/2026

Digital Object Identifier

Communities and Crime Veri Setinin İstatistiksel ve Boyut-İndirgeme Tabanlı Analizi

Serkan Eren¹¹Yapay Zekâ Yüksek Lisans Programı, Bilgisayar Mühendisliği Bölümü, Mühendislik Fakültesi, Gebze Teknik Üniversitesi, Kocaeli, Türkiye

s.eren2018@gtu.edu.tr

Bu çalışma, Gebze Teknik Üniversitesi Yüksek Lisans Programı kapsamında verilen CSE 555: İstatistiksel Veri Analizi dersinin dönem projesi olarak yürütülmüştür.

ABSTRACT Bu çalışma, UCI *Communities and Crime* veri setinin yapısını keşifsel, istatistiksel ve boyut-indirgemeli analizler dizisiyle incelemektedir. Veri setinin 122 öngörücü özneliği, etiketten bağımsız ve veri-güdümlü bir özellik seçim hattıyla önce kırk üç normalize sosyodemografik değişkene indirgenir: düşük kapsama sahip LEMAS öznelikleri çıkarılır, kalan öngörücüler mutlak Pearson korelasyon uzaklığı ($d = 1 - |r|$, tam bağlantı) üzerinde aglomeratif hiyerarşik kümelemeyle gruplanır ve her kümeden bir temsilci tutulur. Sürekli hedef değişken *ViolentCrimesPerPop*, tertillere göre Düşük, Orta ve Yüksek suç sınıflarına ayrıştırılır. Boru hattı; özellik-başına kutu grafiği incelemesi ve Isolation Forest tabanlı çok-değişkenli aykırı değer temizliği, Pearson ve Spearman korelasyon analizi, z-skor normalizasyonu ile özellik-başına Fisher Uzaklığı, temel bileşen analizi (PCA) ile temel bileşen-başına Fisher Uzaklığı, doğrusal ayırma analizi (LDA), ve K-Means, DBSCAN, t-SNE ile Öz-Düzenleyici Harita (SOM) projeksiyonlarının karşılaştırmasını içerir. 2-B gömmelerde sınıf ayrılabilirliği silüet katsayısı ve 5-NN çapraz doğrulama doğruluğu ile nicel olarak raporlanmış; SOM organizasyonu nöron-başına sınıf-saflığı ısı haritasıyla özetlenmiştir. Analiz, aile-yapısı ve sosyoekonomik temsilcilerin (örn. *PctKids2Par*, *PctIlleg*, *PctPopUnderPov*) en güçlü tekil sınıf sinyali taşıdığını, başat PCA bileşeninin bu ayırt edici içeriğin büyük kısmını miras aldığını ve LDA'nın PCA'ya göre daha sıkı sınıf-ayrılabilir bir 2-B gömme ürettiğini göstermektedir. Düşük ve Yüksek sınıfları arasında *PctKids2Par* üzerinde uygulanan Welch t-testi, $n = 36$ ve $n = 64$ için son derece anlamlı bir ortalama farkı ortaya koymaktadır.

INDEX TERMS Communities and Crime, keşifsel veri analizi, hiyerarşik kümeleme, özellik seçimi, Fisher Uzaklığı, PCA, LDA, K-Means, DBSCAN, t-SNE, Öz-Düzenleyici Harita, hipotez testi.

1. GİRİŞ

UCI Makine Öğrenmesi Deposundan elde edilen *Communities and Crime* veri seti [1], Amerika Birleşik Devletleri'nde topluluk düzeyinde şiddet suçunun sosyodemografik modellenmesi için yaygın olarak kullanılan bir kıyaslama veri setidir. Veri seti; 1990 ABD Nüfus Sayımı, 1990 ABD Kolluk Kuvvetleri Yönetim ve İdari İstatistikleri (LEMAS) anketi ve 1995 FBI Birleşik Suç Raporlarından (UCR) elde edilen bilgileri birleştirir ve 128 öznelikle tanımlanan 1 994 topluluk içermektedir. Her öngörücü öznelik, farklı nüfus büyüklüğüne sahip topluluklar arasında karşılaştırmaların anlamlı olabilmesi için veri seti yazarları tarafından [0, 1] aralığına normalize edilmiştir.

Bu çalışmanın amacı rekabetçi bir tahmin modeli inşa etmek değil, CSE 555 dersinde öğretilen istatistiksel veri-analizi araçlarını gerçek, karışık kaliteli bir veri setine uygulamak ve her aracın veri hakkında ortaya koyduğunu yorum-

lamaktır. Projenin merkezî tasarım tercihi; çalışılan özellik kümesinin sübjektif elle seçimini, tamamen veri-güdümlü ve etiket-kör bir boyut indirgeme prosedürüyle değiştirmektir. Somut olarak, düşük kapsamlı öznelikler önce dışlanır; ardından geri kalan öngörücüler mutlak Pearson korelasyon uzaklığı üzerinde aglomeratif hiyerarşik kümeleme ile gruplanır ve her kümeden bir temsilci tutulur. Bu prosedür; demografi, etnik kompozisyon, kentleşme, gelir ve konut maliyeti, eğitim, istihdam, yoksulluk, aile yapısı, göç, konut kalitesi ve ikamet hareketliliği gibi orijinal veri setinin her kavramsal bloğunu kapsayan, küme-içi ikili korelasyonu alttan sınırlı tutan 43 sosyodemografik özelliklik bir çalışma kümesi üretir. Seçim mekanizması Bölüm II'de tanımlanmıştır. Ödevin gerektirdiği çok-sınıflı problemi elde etmek için, sürekli hedef değişken *ViolentCrimesPerPop* tertillere göre eşit-frekanslı üç sınıfa ayrıştırılır: *Düşük*, *Orta* ve

Yüksek.

Makalenin geri kalanı şu şekilde organize edilmiştir. Bölüm II veri setini, eksik veri filtresini ve dendrogram tabanlı özellik seçimini açıklar. Bölüm III–X projenin sekiz analitik görevini sırasıyla ele alır: dağılımlar ve aykırı değerler (Bölüm III), korelasyon analizi (Bölüm IV), z-skor sonrası özellik-başına Fisher Uzaklığı (Bölüm V), PCA tabanlı Fisher analizi (Bölüm VI), en üst ve en alttaki PC saçılım grafikleri (Bölüm VII), LDA (Bölüm VIII), K-Means, DBSCAN, t-SNE ve SOM ile kümeleme (Bölüm IX) ve Welch t-testi (Bölüm X). Bölüm XI temel bulguları özetler.

II. VERİ SETİ VE ÖZELLİK SEÇİMİ

Communities and Crime veri seti [1]; 128 sütunla tanımlanan 1994 topluluk içerir: beş tane öngörücü olmayan tanımlayıcı (state, county, community, communityname, fold), 122 öngörücü aday ve hedef öznitelik ViolentCrimesPerPop. Tüm öngörücü değişkenler, veri seti yazarları tarafından ± 3 standart sapmanın ötesindeki değerleri kıran denetimsiz eşit-aralıklı binning yöntemiyle önceden $[0, 1]$ aralığına normalize edilmiştir; bu normalizasyon değişken-içi dağılım şeklini korur ancak değişkenler arası göreceli büyüklükleri korumaz. Sürekli yanıt ViolentCrimesPerPop, tertillere göre eşit-frekanslı üç sınıfa ayrıştırılır: *Düşük*, *Orta* ve *Yüksek*; bu, temizlik öncesi 679/662/653 örnek dağılımını verir. Tüm işlemler Python 3.10 ortamında NumPy, pandas, scikit-learn [3], scipy, seaborn ve MiniSom [2] kütüphaneleri kullanılarak yürütülmüştür.

A. TANIMLAYICI SÜTUNLARIN VE EKSİK VERİNİN FİLTRELENMESİ

Beş tanımlayıcı sütun ilk adımda düşürülmüştür. Veri seti ardından LEMAS polis-gücü anketinden türetilmiş, 22 değişkenden oluşan bitişik bir blok içerir (örn. LemasSwornFT, PolicPerPop, RacialMatchCommPol); bu blok 1994 topluluğun 1675'i için, yani örneklemin %84'ü için eksiktir. Böylesine derin bir boşluğu doldurmak, sonraki kovaryans-tabanlı yöntemlerde (PCA, LDA, Fisher Uzaklığı) ciddi yapay varyans enjekte ederek tüm analizi kirliletecektir; bu nedenle bu 22 sütun tamamen kaldırılmıştır. Geriye kalan 100 öngörücüde sütun başına en fazla %0.05 eksiklik bulunmakta olup sütun-medyanı ile doldurulmuştur.

B. KORELASYON UZAKLIĞI ÜZERİNDE HİYERARŞİK KÜMELEMEYLE ÖZELLİK SEÇİMİ

Hayatta kalan 100 öngörücü hâlâ ağır kavramsal redundancy taşımaktadır: medIncome, medFamInc, perCapInc, whitePerCap ve mülk-sahip-oturan konut değer çeyrekleri OwnOcc{Low, Med, Hi}Quart'ın tümü aynı alta yatan yapıyı (topluluk varlığı) ölçer ve ikili $|r| > 0,85$ değerlerinde korelasyonludur. Elle düzenlenen bir çalışma kümesi kaçınılmaz olarak analistin önceki beklentilerini yansıtır; biz bu seçimi, özelliklerin ikili-korelasyon geometrisindeki aglomeratif hiyerarşik kümelemesine dayanan tamamen etiket-kör bir prosedürle değiştiririz. Sınıf etiketi seçim sürecinde hiçbir

şekilde danışılmadığı için, sonraki denetimli analizler (Fisher Uzaklığı, LDA, K-NN ayrılabilirliği) seçimden kaynaklanan veri sızıntısından arınmış kalır.

Aynı bilgiyi taşıyan iki özellik, korelasyonlarının işaretinden bağımsız olarak redundant kabul edilmelidir: racePctWhite ve racePctBlack $r \approx -0,85$ civarında korelasyonludur fakat tek bir etnik-kompozisyon eksenini kodlamaktadır. Bu nedenle, mutlak değerli Pearson korelasyon uzaklığını kullanırız:

$$d_{ij} = 1 - |r_{ij}|, \quad d_{ij} \in [0, 1], \quad (1)$$

bu tanım, hem mükemmel pozitif hem mükemmel negatif korelasyonlu çiftleri $d = 0$ 'a, istatistiksel olarak bağımsız çiftleri ise $d = 1$ 'e götürür. 100 öngörücü üzerindeki sıkıştırılmış ikili uzaklık matrisi, *tam bağlantı* (complete linkage) ile aglomeratif kümelemeye verilir. Tam bağlantı, iki kümeyi yalnızca aralarındaki *en büyük* ikili uzaklık eşiği aşımadığında birleştirir; bu, ortaya çıkan her kümede ikili korelasyonun en az $1 - d_{th}$ ile alttan sınırlanmasını garanti eder. Ortalama ve tekil bağlantı bu garantiyi sağlamaz ve sıkı ile gevşek korelasyonlu üyeleri karıştıran kümeler üretir.

$d_{th} \in \{0,20, 0,25, \dots, 0,60\}$ aralığında bir eşik taraması sırasıyla 57 ile 29 arasında küme verir. $d_{th} = 0,35$ çalışma noktası — küme-içi korelasyon tabanı $|r| \geq 0,65$ 'e karşılık gelen — benimsenmiştir. Bu seçim tam olarak 43 küme üretir; bu, dört büyük belirgin redundancy bloğunun (gelir/varlık, aile yapısı, yoksunluk ve yakın göç payları) tek gruplara konsolide olduğu, ama kavramsal olarak ayrı boyutların (örn. göç yakınlık oranları ile nüfus içindeki göçmen payı, ya da iki-ebeveynli haneler ile hiç evlenmemiş anneler) ayrı kaldığı en küçük küme sayısıdır. Şekil 1 elde edilen dendrogramı, kesim çizgisi ve renk-kodlu kümelerle birlikte göstermektedir.

C. KÜME TEMSİLCİSİNİN SEÇİMİ

43 kümenin her birinden tam olarak bir temsilci tutulur. Singleton kümelerde temsilci, kümenin tek üyesidir (24 singleton). Çok-üyeliler her küme için varsayılan kural, *merkez* (centroid) özelliği almaktır; yani diğer üyelere ortalama ikili korelasyon uzaklığı en düşük olan üye, kümeyi kendi başına en iyi özetleyen özelliktir. 19 çok-üyeliler kümeden 7'sinde merkez, kriminoloji ve sosyal-bilimler literatüründe yaygın kullanılan bir değişkenle örtüşmekte olduğundan olduğu gibi tutulmuştur. Diğer 12 çok-üyeliler kümede ise, yorumlanabilirlik-güdümlü bir geçersiz kılma uygulanarak yakın-eşdeğer merkez yerine kanonik literatür değişkeni tercih edilmiştir (örn. gelir-ve-varlık kümesinde merkez RentHighQ yerine medIncome'a geçilmiştir; çünkü medyan gelir, ilgili literatürde topluluk-varlığının standart vekil değişkenidir). Tüm geçersiz kılmalar, yer aldıkları kümenin içinde kalır; bu nedenle küme-içi korelasyon garantisi korunur. Çok-üyeliler kümeler ve nihai temsilcileri Tablo 1'de listelenmiştir.

D. NİHAİ ÇALIŞMA KÜMESİ

Bölüm II-A–II-C'deki prosedür, 43 özellikten oluşan deterministik bir çalışma kümesi üretir — 24'ü singleton




FIGURE 1. 100 öngörücü adayının mutlak Pearson korelasyon uzaklığı $d = 1 - |r|$ üzerinde tam bağlantı ile aglomeratif hiyerarşik kümelemesi. $d = 0.35$ değerindeki yatay kırmızı çizgi, 43 küme üreten ve küme-ici korelasyon tabanını $|r| \geq 0.65$ ile sınırlandıran kesimdir. Kesim altında herhangi bir alt-ağaca katılmayan (yani $d \approx 1$ 'e ulaşan dikey yapraklar) singleton kümeler, kavramsal olarak benzersiz bilgi taşıyan özelliklere karşılık gelir.

TABLE 1. $d_{th} = 0.35$ 'te elde edilen 19 çok-üyelı küme, üyeleri ve sonraki analizler için tutulan temsilcileri. “*” algoritmik merkezi işaretler; seçilen temsilci koyu olarak gösterilmiştir. Singleton kümeler (24 özellik) Tablo 2’de listelenmiştir.

Küme	Boyut	Tema	Üyeler (merkez *, temsilci koyu)
1	11	Gelir / varlık	medIncome , medFamInc, perCapInc, whitePerCap, OwnOcc{Low,Med,Hi}Quart, Rent{Low,Med}Q, RentHighQ*, MedRent
6	7	Aile yapısı	MalePctDivorce, FemalePctDiv, TotalPctDiv, PctFam2Par*, PctKids2Par , PctYoungKids2Par, PctTeen2Par
7	3	Konut sahipliği	PctPersOwnOccup*, PctHousLess3BR, PctHousOwnOcc
10	7	Yoksunluk	pctWinInc, pctWPubAsst, PctPopUnderPov , PctLess9thGrade, PctNotHSGrad*, PctUnemployed, PctHousNoPhone
12	3	İrk / evlilik-dışı doğum	racepctblack, racePctWhite, PctIlleg*
15	3	Eğitim / meslek	PctBSorMore , PctOccupManu, PctOccupMgmtProf*
22	5	Göç payı	PctRecentImmig, PctRecImmig5, PctRecImmig8*, PctRecImmig10, PctForeignBorn
25	2	İstihdam	pctWWage*, PctEmploy
26	3	Yaşlı / emeklilik	agePct65up* , pctWSocSec, pctWRetire
29	2	Eyalet-düzeyi ikamet	PctBornSameState* , PctSameState85
30	2	Yerel ikamet	PctSameHouse85* , PctSameCity85
32	6	Nüfusa ölçekli sayımlar	population* , numbUrban, NumUnderPov, NumIlleg, HousVacant, NumInShelters
33	2	Nüfusa ölçekli sayımlar	NumImmig* , NumStreet
36	4	Göç yakınlığı	PctImmigRecent, PctImmigRec5, PctImmigRec8* , PctImmigRec10
37	3	Genç yaş yapısı	agePct12t21, agePct12t29 , agePct16t24*
40	2	Çalışan annelik	PctWorkMomYoungKids*, PctWorkMom
41	4	Hane büyüklüğü	householdsize , PersPerFam, PersPerOccupHous*, PersPerOwnOc-cHous
42	3	Hispanik / dil	racePctHisp , PctSpeakEnglOnly, PctNotSpeakEnglWell*
43	4	Kalabalık barınma	PctLargHouseFam, PctLargHouseOccup*, PersPerRentOccHous, PctPersDenseHous

TABLE 2. Kavramsal bloklara göre gruplandırılmış 43 tutulan özellik. Tüm değişkenler veri seti yazarları tarafından zaten [0, 1] aralığına normalize edilmiştir.

Blok	Özellikler
Demografi	population, householdsize, agePct12t29, agePct65up, racePctAsian, racePctHisp
Kentleşme	pctUrban, PopDens, PctUsePubTrans, LandArea
Gelir / varlık	medIncome, blackPerCap, HispPerCap, AsianPerCap, indianPerCap, OtherPerCap
Konut maliyeti	MedOwnCostPctInc, MedOwnCostPctIncNoMtg, MedRentPctHousInc
Eğitim	PctBSorMore
İstihdam	PctEmploy, PctEmplProfServ, PctEmplManu, pctWFarmSelf
Yoksulluk	PctPopUnderPov
Aile	PctKids2Par, PctIlleg, MalePctNevMarr, PctWorkMom
Göç	NumImmig, PctForeignBorn, PctImmigRec8
Konut kalitesi	PctHousOwnOcc, MedNumBR, PctVacantBoarded, PctHousOccup, PctVacMore6Mos, MedYrHousBuilt, PctWOFullPlumb, PctPersDenseHous
Hareketlilik	PctBornSameState, PctSameHouse85
Polislik	LemasPctOfficDrugUn

kümelerden, 19'u çok-üyelik kümelerden gelmek üzere — Tablo 2'de kavramsal bloklara göre listelenmiştir. Tutulan her özellik, veride redundant olmayan bir varyasyon eksenini temsil eder; daha kesin ifadeyle, hiçbir iki tutulan özellik seçilen korelasyon tabanı altında aynı hiyerarşik-kümeleme kümesinin içinde yer almaz. Kümeler-arası korelasyonlar bu prosedürle elbette sınırlanmaz: örneğin 12. kümenin temsilcisi PctIlleg ile 6. kümenin temsilcisi PctKids2Par, hâlâ $|r| \approx 0,87$ ile korelasyonludur; çünkü dendrogram bu iki özelliği, kavramsal olarak yakın fakat birbirinden ayrılabilir iki “yoğunlaşmış dezavantaj” eksenini ifşa eder. Bu küme-arası kalan korelasyon, veri setine ilişkin başlı başına bir gözlemdir ve Bölüm IV ile VI'de tekrar ele alınmıştır. Aynı 43-özellik çalışma kümesi, sonraki tüm analizlerde kullanılır.

III. DAĞILIMLAR VE AYKIRI DEĞER TESPİTİ (GÖREV 1)

Şekil 2, seçilen 43 değişkenin aykırı değer temizliği öncesi özellik-başına kutu grafiklerini, okunabilirlik için iki panele bölünmüş ve kavramsal bloklara göre etiketlenmiş biçimde sunmaktadır. Üç dağılım örüntüsü göze çarpar. İlk olarak, birçok özellik güçlü biçimde sağa çarpıktır ve uzun bir üst kuyruğa sahiptir — en belirgin olarak population, PopDens, LandArea, NumImmig, PctIlleg ve PctVacantBoarded; bu kuyruklar, demografik veya sosyoekonomik olarak uç noktada bulunan küçük bir topluluk kümesini yansıtır (çok büyük ya da yoğun şehirler, çok yüksek göçmen sayıları veya yoğunlaşmış yoksulluk). İkincisi, koruyucu aile ve konut değişkenleri (PctKids2Par, PctHousOwnOcc, PctEmploy) sola çarpıktır; uzun bir alt kuyrukları dezavantajlı topluluklardan




FIGURE 2. Aykırı değer temizliği öncesinde seçilen 43 özelliğin, kavramsal bloklara göre gruplandırılmış kutu grafikleri. Birçok sosyoekonomik değişken uzun üst kuyruklu sağa-çarpıklık gösterir, aile/konut koruyucu değişkenleri sola-çarpıktır ve pctUrban iki-modludur.

TABLE 3. 43-özellik çalışma kümesinde aykırı değer temizleme karşılaştırması. Özellik-başına IQR kuralı yalnızca reddedilen bir taban olarak gösterilmiştir; fiilen kullanılan yöntem çok-değişkenli Isolation Forest'tir.

	Öncesi	IQR ($k = 3$)	Isolation Forest
Tutulan satır	1 994	1 264	1 894
Atılan satır	—	730 (%36,6)	100 (%5,0)
Düşük	679	524 (−%22,8)	660 (−%2,8)
Orta	662	445 (−%32,8)	649 (−%2,0)
Yüksek	653	295 (−%54,8)	585 (−%10,4)

oluşur. Üçüncüsü, pctUrban belirgin biçimde iki-modludur (bimodal): kutusu neredeyse tüm [0, 1] aralığını kaplar; çünkü topluluklar ağırlıklı olarak ya tamamen kentsel (≈ 1) ya da tamamen kırsaldır (≈ 0); bu, sonraki bölümlerdeki projeksiyonları yorumlarken hatırlanması gereken bir özelliktir. Buna karşılık agePct12t29, agePct65up ve kişi-başı gelir değişkenleri medyanları etrafında sıkıca toplanmıştır.

Neden çok-değişkenli bir detektör. Univariate IQR reddi gibi bir özellik-başına filtre, herhangi bir tek boyutta uç değer taşıyan örneği atar. Bu, buradaki veri için iki kez uygunsuzdur. Kavramsal olarak, birkaç sınıf-ayrıt edici özellik (PctPopUnderPov, PctIlleg, PctVacantBoarded) doğası gereği neredeyse yalnızca Yüksek-suç topluluklarından oluşan ağır üst kuyruklar taşır; dolayısıyla marjinal kırpmaya, tam da analizin betimlemeye çalıştığı sınıfı boşaltır. İstatistiksel olarak, bir satırın işaretlenme olasılığı özellik sayısı ile hızla artar; çünkü bir satır, 43 marjinalden *en az birinde* eşliği aştığı anda reddedilir — bu, boyutun lanetinin doğrudan bir tezahürüdür. Tablo 3 her iki etkiyi de niceler: $k = 3$ çarpanlı özellik-başına IQR kuralı 730 satırı (verinin %36,6'sı) atar ve Yüksek-suç sınıfını yarıdan fazla çökertir ($653 \rightarrow 295$, −%54,8); bu da Bölüm V–VIII'deki denetimli analizleri anlamsız kılar.

Bu nedenle nihai boru hattı, scikit-learn [3] kütüphanesinin çok-değişkenli Isolation Forest [4] yöntemini




FIGURE 3. Isolation Forest temizliği (kirlilik = 0.05) sonrası kutu grafikleri. Her dağılımın ana gövdesi korunur, ancak marjinal aykırı değer noktaları (bıyıkların ötesindeki daireler) hâlâ görünürdü – detektörün özellikle-başına uç değerleri değil birleşik anomalileri kaldırdığını doğrudan görsel kanıtı.

200 ağaç ve %5 kirlilik (contamination) oranıyla kullanır. Detektör, her örneği özellik uzayının özyinelemeli rastgele bölünmesiyle yalıtır; yalıtılması olağandışı biçimde az sayıda rastgele bölme gerektiren bir örnek, 43-boyutlu uzayın seyrek bir bölgesinde yer alır ve *birleşik* (joint) bir anomali olarak işaretlenir. Kirlilik = 0,05 ile filtre 100 satırı (%5,0) atar ve geriye sınıf dağılımı *Düşük*: 660, *Orta*: 649, *Yüksek*: 585 olan 1 894 topluluk bırakır (Tablo 3). Dikkat çekici olarak, Yüksek-sınıf daralması 43-özellik kümesinde (–%10,4), daha küçük bir 18-özellik kümesine kıyasla (ön denemelerde –%11,6) *daha hafiftir*: ek boyutlar, detektöre meşru biçimde uç noktada bulunan Yüksek-suç topluluklarını, aynı anda birçok eksenle gerçekten anomali olan topluluklardan ayırt etmek için daha fazla kanıt sağlar.

İnce ama önemli bir doğrulama Şekil 3'da görülebilir: birçok marjinal aykırı değer noktası (bıyıkların ötesindeki daireler) temizlik sonrasında *korunmaktadır*. Özellik-başına bir IQR kuralı, yapısı gereği bıyıkların ötesinde hiç nokta bırakmayan kutu grafikleri üretti; bu noktaların burada varlığını sürdürmesi, Isolation Forest'ın bireysel bir eksende yalnızca uç olan değil, *birleşik* 43-boyutlu dağılımda anomali olan örnekleri hedeflediğini gösterir. Her özellik dağılımının niteliksel şekli — çarpıklık, medyan ve çeyrekler-arası açıklık — korunmuştur ve sonraki tüm analizler bu temizlenmiş 1 894 topluluk veri setini kullanır.

IV. KORELASYON ANALİZİ (GÖREV 2)

43 özellik ile ordinal kodlanmış sınıf etiketi arasındaki tam Pearson korelasyon matrisi Şekil 4’da gösterilmektedir. 44 satırla hücre-başına sayısal etiketler okunamaz olacağından bunlar çıkarılmış ve Tablo 2’deki kavramsal-blok sınırları siyah ayrılarlar olarak çizilmiştir; bu durumda yalnızca renk alanı makro-yapıyı okunur kılar. Bölüm II’in dendrogramının açığa çıkardığı aynı iki zıt süper-blok, burada korelasyon uzayında yeniden belirir. Bir *avantaj* süper-bloğu — medyan gelir ve kişi-başı gelir değişkenleri, eğitim (PctBSorMore),




FIGURE 4. 43 özellik ile ordinal kodlanmış suç sınıfının Pearson korelasyon matrisi. Okunabilirlik için sayısal etiketler çıkarılmıştır; siyah çizgiler Tablo 2'deki kavramsal-blok sınırlarını işaretler. Zıt sıcak/soguk bloklar, avantaj–dezavantaj sosyoekonomik gradyanıdır.




FIGURE 5. 43 özelliğin tamamının suç sınıfı (ordinal) ile özellik-başına Pearson korelasyonu, sıralanmış halde. Kırmızı çubuklar yüksek suç düzeyleriyle pozitif korelasyonu, mavi çubuklar negatif (koruyucu) korelasyonu gösterir.

istihdam (PctEmploy), aile istikrarı (PctKids2Par) ve konut sahipliği (PctHousOwnOcc, MedNumBR) — kendi içinde pozitif korelasyonludur. Bir *dezavantaj* süper-bloğu — yoksulluk (PctPopUnderPov), evlilik-dışı doğum (PctIlleg), aşırı kalabalıklaşma (PctPersDenseHous) ve konut çürümesi (PctVacantBoarded) — benzer biçimde kendi içinde pozitif korelasyonludur. İki süper-blok birbiriyle güçlü biçimde negatif korelasyonludur; bu, makalenin geri kalanının tekrar tekrar geri kazandığı, iyi bilinen sosyoekonomik “avantaj–dezavantaj” gradyanıdır.

Şekil 5, 43 özelliğin tamamını suç sınıfı (ordinal) ile korelasyonlarına göre sıralar. En güçlü tekil korelasyonlar PctKids2Par (-0,69), PctIlleg (+0,62), PctPopUnderPov (+0,52), PctPersDenseHous (+0,47), PctHousOwnOcc (-0,46), medIncome (-0,45) ve PctVacantBoarded (+0,38)'dir. İşaretler, topluluk

düzeyinde suçun sosyal-düzensizlik açıklamasıyla tutarlıdır: aile istikrarı, gelir, eğitim ve istikrarlı mülk-sahibi-oturan konut koruyucudur; buna karşılık yoksulluk, aile parçalanması ve konut çürümesi daha yüksek şiddet suçuyla birlikte görülür. İki gözlem veri-güdümlü 43-özellik kümesine özgüdür. İlki, PctPersDenseHous (oda başına birden fazla kişi barındıran konutta yaşayan nüfus oranı) dördüncü en güçlü tekil korelasyon olarak belirir; bu aşırı kalabalıklaşma sinyali yoksulluktan kavramsal olarak ayrıdır ve daha küçük, elle seçilmiş bir kümede gözden kaçması kolay olurdu; ancak kümeleme boru hattı onu kendi bloğunun temsilcisi olarak tutar. İkincisi, konut-kalitesi bloğu rastlantısal değil kolektif olarak öngörücüdür: PctHousOwnOcc, PctVacantBoarded, PctHousOccup ve MedNumBR'nin tümü ilk on içinde yer alır; bu, konut stokunun fiziksel durumunun topluluk suçunu, kanonik gelir ve aile değişkenleri kadar yakından izlediğini gösterir. Diğer uçta, demografik ve coğrafi değişkenler — pctUrban, LandArea, agePct65up, householdsize, MedYrHousBuilt ve etnisiteye-özgü kişi-başı gelir değişkenleri — esasen hiçbir tekil sınıf sinyali taşımaz.

Sınıf etiketi aralık-ölçekli bir değişken yerine *ordinal* bir tertil olduğundan, özellik-sınıf ilişkisi için Spearman sıra korelasyonu da hesaplanmıştır. Spearman büyüklükleri tipik olarak biraz daha büyüktür (örn. PctKids2Par $-0,70$, PctIlleg $+0,69$, PctPopUnderPov $+0,57$). En belirgin kayma PctPersDenseHous'dur; $+0,47$ 'den (Pearson) $+0,61$ 'e (Spearman, genel üçüncü) yükselir; bu boşluk, aşırı kalabalıklaşmanın suç tertili ile monotonik ama *doğrusal-olmayan* biçimde ilişkili olduğunu, yani yoğunluk kritik bir düzeyi aştığında suçun keskin biçimde yükseldiği bir eşik etkisini düşündürür. Bu tür tekil kaymalara rağmen, iki metrik altında özelliklerin mutlak-korelasyon *sıralaması* neredeyse aynıdır (Spearman sıra uyumu $0,97$); bu da bu bölümün niteliksel sonuçlarının, ordinal sınıf etiketini aralık-ölçekli muamele etmenin yapay sonuçları olmadığını doğrular.

V. Z-SKOR NORMALİZASYONU VE ÖZELLİK-BAŞINA FISHER UZAKLIĞI (GÖREV 3)

Z-skor normalizasyonundan sonra, özellik-başına Fisher Uzaklığı klasik iki-sınıflı Fisher skorunun çok-sınıflı bir genellemesi olarak hesaplanmıştır:

$$J(f) = \frac{\sum_{c=1}^C n_c (\mu_c^{(f)} - \mu^{(f)})^2}{\sum_{c=1}^C \sum_{i \in c} (x_i^{(f)} - \mu_c^{(f)})^2}, \quad (2)$$

burada $\mu_c^{(f)}$, f özelliğinin c sınıfındaki ortalaması, $\mu^{(f)}$ ise küresel ortalamasıdır. Büyük $J(f)$, f özelliğinin sınıf ortalamalarını sınıf-içi dağılıma göre iyi ayırdığını gösterir. Z-skorlama, paydadaki sınıf-içi saçılma (S_W) farklı varyanslı özellikler arasında adil biçimde karşılaştırılabilir diye gereklidir.

Elde edilen sıralama (Şekil 6), Bölüm IV'ün korelasyon sıralamasıyla neredeyse aynıdır; bu beklenen bir sonuçtur: tek bir z-skorlanmış özellik için hem Fisher Uzak-




FIGURE 6. Z-skor normalizasyonu sonrası özellik-başına Fisher Uzaklığı, 43 özelliğin tamamı sıralanmış halde. PctKids2Par ve PctIlleg domine eder; özelliklerin yaklaşık yarısı sıfıra yakın Fisher Uzaklığına sahiptir.

lığı hem de mutlak sınıf korelasyonu, sınıf ortalamaları arasındaki kontrastı sınıf-içi saçılmaya göre ölçer. En üst iki özellik PctKids2Par ($J = 0,90$) ve PctIlleg ($J = 0,69$) olup, bunları PctPopUnderPov ($0,37$), PctPersDenseHous ($0,28$), PctHousOwnOcc ($0,27$) ve medIncome ($0,26$) izler. İki yapısal gözlem öne çıkar. İlki, ayırt edici içerik keskin biçimde yoğunlaşmıştır: PctKids2Par ve PctIlleg diğer her özelliği gölgede bırakır ve üçüncü sıradaki PctPopUnderPov'a doğru büyük bir düşüş vardır; onun skoru PctIlleg'inin yarısından azdır. İkincisi, 43 özelliğin yaklaşık yarısı $0,03$ 'ün altında Fisher Uzaklığına sahiptir — pctUrban ve PctUsePubTrans etkin biçimde sıfırdır ($J \approx 2 \times 10^{-4}$); konut-maliyeti oranları MedOwnCostPctInc ve MedYrHousBuilt de öyle. Başka bir deyişle, çalışma kümesi 43 kavramsal olarak ayrı eksen kapsasa da, tek-özellik sınıf sinyali bunların yalnızca yaklaşık altı ila onunda yaşar. Bu yoğunlaşma, Bölüm VI'nın temel bileşen analizini önceler: çoğu tekil eksen sınıf-bilgisiz olduğunda ve bilgili olanlar birbiriyle korelasyonlu olduğunda, çok az sayıda doğrusal kombinasyon ayrılabilirliğin neredeyse tamamını yakalamalıdır.

VI. PCA VE TEMEL BİLEŞEN-BAŞINA FISHER UZAKLIĞI (GÖREV 4)

Z-skorlanmış veriye PCA uygulanarak 43 temel bileşen üretilmiştir. Başat bileşen PC1 varyansın $\%18,6$ 'sını, PC2 ise ek olarak $\%14,3$ 'ünü açıklar; ilk beş bileşen birlikte toplam




FIGURE 7. 43-özellik çalışma kümesi için PCA scree grafiği. PC1 varyansın %18,6'sını, PC2 ek %14,3'ünü yakalar; ilk beş bileşen %53,4'ü, %80 için on altı bileşen gereklidir.




FIGURE 8. Z-skorlanmış orijinal özellik-başına (sol) ve temel bileşen-başına (sağ) Fisher Uzaklığı, ortak dikey ölçekte. Özellik-başına sinyal birkaç değişkene yayılırken, PC-başına sinyal neredeyse tamamen PC1'de yoğunlaşmıştır.

varyansın yalnızca %53,4'ünü oluşturur ve %80'e ulaşmak için on altı bileşen gerekir (Şekil 7). Bu nedenle scree eğrisi, küçük elle-seçilmiş bir özellik kümesine kıyasla çok daha düzdür: 43 özellik kasıtlı olarak birçok zayıf-korelasyonlu kavramsal bloğu kapsadığından, varyans tek bir başat ekseninde toplanmak yerine birçok yöne dağılır.

Her PC projeksiyonu bir özellik gibi ele alınarak Denklem (2)'deki Fisher Uzaklığı yeniden hesaplanmıştır (Şekil 8). PC1'in Fisher Uzaklığı 0,56 olup temel bileşenler arasında açık ara en büyüğüdür; diğer her PC 0,07'nin altında skor alır. Ancak kritik biçimde, PC1'in 0,56'sı en iyi iki orijinal özellikten ($PctKids2Par$ 0,90 ve $PctIllegal$ 0,69) bile *daha düşüktür*. Denetimsiz başat bileşen, dolayısıyla, en iyi ham özelliği basitçe tutmaktan daha kötü bir tek-eksenli sınıf ayıracıdır; çünkü PC1 toplam varyansı maksimize etmek üzere kurulur ve ayırt edici “avantaj-dezavantaj” yönünü, korelasyonlu ama daha az ayırt edici varyasyonla zorunlu olarak harmanlar. Bu, Bölüm VIII'nin denetimli projeksiyonunun (LDA) temel gereğesidir.

Bir temel bileşenin eigenvalue'su (varyansı) ile Fisher Uzaklığı arasındaki ilişki pozitif ama zayıftır ve tamamen başat bileşende yoğunlaşmıştır: Pearson korelasyonu $r = 0,76$, Spearman sıra korelasyonu ise yalnızca $\rho = 0,49$ 'dur (Şekil 9). Yüksek Pearson katsayısı, saçılımın uzak köşesinde hem en büyük eigenvalue'ya hem de açık ara en büyük Fisher Uzaklığına sahip PC1 tarafından tek başına sürüklenen bir




FIGURE 9. 43 temel bileşen için eigenvalue'ya karşı Fisher Uzaklığı. Pearson korelasyonu $r = 0,76$, Spearman $\rho = 0,49$. PC2 ikinci en büyük eigenvalue'ya sahip olmasına rağmen sıfıra yakın Fisher Uzaklığı taşır.

yapay sonuçtur; PC1 çıkarıldığında eigenvalue–Fisher ilişkisi esasen kaybolur. En açık örnek **PC2**'dir: ikinci en büyük varyansı (%14,3) taşımasına karşın Fisher Uzaklığı sıfıra yakındır (0,06); PC3 (üçüncü en büyük varyans) ise yalnızca 0,01 alır. Bu yüksek-varyanslı, sınıf-ilgisiz bileşenler, PCA'nın varyansı maksimize ettiğinin, sınıf ayrılabilirliğini *değil*, ders kitabı uyarısının doğrudan bir göstergesidir: PC2, suç gradyanına dik — üç sınıfın esasen ayırt edilemez olduğu — büyük bir topluluk-varyasyon eksenini yakalar. Yalnızca PC1 ayırt edici yönle hizalanır, o bile kusurlu biçimde. Bu, daha küçük bir özellik kümesinin düşündüreceğinden daha nüanslı bir tablodur; orada PC1 tek başına hem varyansı hem ayrılabilirliği domine etme eğilimindedir. Tam 43-boyutlu kümede ise varyans ve ayırt edicilik, başat bileşenin ötesinde açıkça ayrışır.

VII. EN ÜST VE EN ALTTAKİ İKİ TEMEL BİLEŞEN ÜZERİNDE SAÇILIM GRAFİKLERİ (GÖREV 5)

Şekil 10, temizlenmiş verinin en önemli iki ve en önemsiz iki temel bileşen üzerine projeksiyonunu, örnekler gerçek sınıf etiketlerine göre renklendirilmiş biçimde gösterir.

(PC1, PC2) grafiği, Bölüm VI'daki ayrışmayı doğrudan görünür kılar. Yatay PC1 eksenı boyunca üç sınıf temiz, neredeyse monoton bir gradyan oluşturur: *Düşük*-suç toplulukları negatif tarafta, *Yüksek*-suç toplulukları pozitif tarafta yoğunlaşır ve *Orta* topluluklar aradaki örtüşen bir bantta yer alır. Buna karşılık dikey PC2 eksenı boyunca üç sınıf tamamen iç içe geçmiştir: ikinci en büyük varyansı (%14,3) taşımasına rağmen PC2 hiçbir sınıf ayrımı sağlamaz. Grafiğin tüm dikey yayılımı dolayısıyla sınıf-ilgisiz varyasyondur — PC2'nin sıfıra yakın Fisher Uzaklığının görsel karşılığı — ve bir topluluğu yüksek-suçlu kılan şeyin, en büyük rakip varyasyon eksenı üzerindeki konumu değil, tek PC1 “avantaj-dezavantaj” eksenı üzerindeki konumu olduğunu doğrular. Her biri varyansın yalnızca %0,1'ini yakalayan en önemsiz iki bileşen (PC42, PC43) üzerine projeksiyon ise zıt uçu gösterir: üç sınıf, gürültü-benzeri artık varyans yakalayan




FIGURE 10. Üst: (PC1, PC2) üzerine projeksiyon. Yatay PC1 eksenine boyunca Düşük → Orta → Yüksek monoton bir sıralama belirirken, dikey PC2 eksenine hiçbir ayırım katmaz. Alt: en önemsiz iki PC (PC42, PC43) üzerine projeksiyon; hiçbir sınıf yapısı göstermez.

TABLE 4. 2-B PCA ve LDA gömmelerinin nicel ayrılabilirliği. Her iki ölçüde de yüksek değer daha iyidir.

Ölçü	PCA (PC1,PC2)	LDA (LD1,LD2)
Silüet (gerçek etiketler)	0,049	0,127
5-NN doğruluk (5-kat ÇD)	0,569	0,659

yönler için beklendiği gibi, ayırt edilebilir hiçbir yapı olmaksızın küçük izotropik bir bulutta iç içe geçer.

VIII. LDA PROJEKSİYONU VE SINIF-AYRILABİLİRLİĞİNİN KARŞILAŞTIRILMASI (GÖREV 6)

$n_{\text{bileşen}} = 2$ ile bir Doğrusal Ayırma Analizi (LDA) uygulanmıştır. Yapısı gereği LDA, sınıflar-arası saçılmayı sınıf-İçi saçılmaya göre maksimize eder ve bu nedenle sınıf bilgisi mevcut olduğunda PCA'ya kıyasla daha sıkı sınıf-ayrılabilir bir 2-B gömme üretme eğilimindedir.

Karşılaştırmayı nicel kılmak için — ödevin istediği bonus — 2-B gömmelerde iki ölçü hesaplanmıştır (Tablo 4). Silüet




FIGURE 11. LDA 2-B projeksiyonu. Üç sınıf, PCA projeksiyonuna kıyasla LD1 eksenine boyunca daha net bir sol-sağ sıralama oluşturur.

TABLE 5. Küme atamaları ile gerçek sınıf etiketleri arasındaki Düzeltilmiş Rand İndeksi (ARI) ve Normalize Karşılıklı Bilgi (NMI).

Yöntem (girdi)	ARI	NMI
K-Means, $k = 3$ (PCA-2B)	0,142	0,147
DBSCAN ($\epsilon = 0,5$) (PCA-2B)	0,018	0,039

katsayısı (gerçek sınıf etiketleri bölümlene olarak kullanılarak) PCA için 0,049'dan LDA için 0,127'ye yükselir; bu yaklaşık %160'lık ($2,6 \times$) bir artıştır. 2-B gömme üzerinde eğitilen bir 5-NN sınıflandırıcının ortalama 5-kat çapraz-doğrulanmış doğruluğu PCA'da %56,9'dan LDA'da %65,9'a iyileşir; bu +9,0 yüzde puanlık bir kazançtır. Her iki ölçü de Şekil 10 ve 11'nin gösterdiğini doğrular: LDA, PCA'ya kıyasla belirgin biçimde daha sıkı sınıf ayrılabilirliği ortaya koyar. Önemli olarak, bu fark 43-özellik kümesinde, düşük-boyutlu bir analizin düşündüreceğinden *daha geniş* ve nedeni doğrudan Bölüm VI'dan gelir. PCA gömmesi iki ekseninden birini (PC2) mevcut en büyük varyans yönüne harcamak zorundadır; Görev 4 bu yönün sınıf-İlgisiz olduğunu göstermiştir; yalnızca PC1 sınıf sinyali taşır, dolayısıyla PCA etkin biçimde tek kullanışlı ayırt edici eksene sahiptir. Dene-timli olan LDA ise *her iki* eksenini de sınıflar-arası saçıl-mayı sınıf-İçine göre maksimize edecek şekilde yönlendirir ve böylece zengin 43-boyutlu özellik uzayından çok daha verimli yararlanır. Kısacası, PCA 2-B bütçesinin yarısını sınıf-İlgisiz varyansa harcarken LDA harcamaz; ölçü farkı tam olarak bu farkı niceler.

IX. KÜMELEME KARŞILAŞTIRMASI: K-MEANS, DBSCAN, T-SNE, SOM (GÖREV 7)

Dört algoritma, ödevin gerektirdiği gibi iki farklı girdiyle uygulanmıştır. K-Means ($k = 3$) ve DBSCAN ($\epsilon = 0,5$, $\text{minPts} = 10$) 2-B PCA projeksiyonu (PC1, PC2) üzerinde çalışır. t-SNE (perplexity 30, PCA başlatma) ve 12×12 MiniSom [2] ise tam 43-boyutlu z-skorlanmış veriye uygulanır.




FIGURE 12. (PC1, PC2) projeksiyonu üzerinde K-Means ($k = 3$). Sol: gerçek sınıflar; sağ: atanan kümeler.




FIGURE 13. (PC1, PC2) üzerinde DBSCAN ($\epsilon = 0.5$, $\text{minPts} = 10$). Verinin büyük kısmı tek bir baskın yoğun kümede toplanır (artı birkaç küçük kenar kümesi), 233 örnek (%12,3) gürültü olarak işaretlenir.




FIGURE 14. Tam 43-boyutlu z-skordanmış verinin, gerçek sınıfa göre renklendirilmiş t-SNE gömmesi. Gömme boyunca sürekli bir gradyan görünür.

a: K-Means

(PC1, PC2) düzleminde, sınırları PC1 boyunca kabaca dikey kesimler olan üç küme bulur; bu Bölüm VII'deki gradyanı yansıtır. İki girdi ekseninden yalnızca PC1 sınıf sinyali taşıdığından, onun boyunca bölümlenme gerçek etiketlerle bir miktar uyum verir ($\text{ARI} = 0,14$, $\text{NMI} = 0,15$); ancak bu uyum, küçük-özellikli bir analizden vereceğinden zayıftır. Nedeni Bölüm VI–VIII'da saptanan aynı ayrışmadır: K-Means PC1 ve PC2'yi izotropik biçimde ele alır; oysa PC2 (varyansın %14,3'ü) sınıf-ilgisizdir; dolayısıyla bölümlenme çabasının önemli bir kısmı toplulukları suçla ilgisiz bir




FIGURE 15. Orijinal z-skordanmış veride eğitilmiş 12×12 MiniSom. Sol: kazananların gerçek sınıfa göre saçılımı (görünürlük için titrestirilmiş). Orta: nöron-başına vuruş-sayısı ısı haritası. Sağ: nöron-başına baskın sınıf ve hücre-başına saflık (metin etiketleri, % olarak); boş olmayan hücrelerin ortalama saflığı %67,5'tir.

yön boyunca ayırmaya harcanır. PCA düzleminde denetimsiz kümeleme, böylece PCA'nın kendi zayıflığını miras alır.

b: DBSCAN

esasen başarısız olur: $\epsilon = 0,5$, $\text{minPts} = 10$ ile tek bir baskın yoğun küme, birkaç küçük kenar kümesi ve 233 gürültü noktası (%12,3) üretir; ARI yalnızca 0,018'dir. Veri, iyi-ayrılmış yoğunluk modları yerine tek bir sürekli “sosyoekonomik gradyan” oluşturduğundan, yoğunluk-tabanlı kümeleme üç sınıfı geri kazanamaz; DBSCAN, bu veri setinin sınıf yapısının modal değil gradyan-benzeri olduğunu açığa çıkarır.

c: t-SNE

tam 43-boyutlu veride, üç sınıfın ayrık adalar yerine sürekli bir gradyan oluşturduğu (Düşük bir uçta, Yüksek diğer uçta) tek, yumuşak değişen bir nokta bulutu üretir. Bu, sınıfların büyük ölçüde tek-boyutlu bir sosyoekonomik süreklilik üzerindeki konumla tanımlandığı — kompakt modal kümelerle değil — görüşünü pekiştirir; aynı sonuca PCA, DBSCAN ve SOM bağımsız olarak ulaşır.

d: SOM

12×12 MiniSom ızgarası (Şekil 15) en sınıf-organize doğrusal-olmayan görünümü sağlar. Vuruş-sayısı ısı haritası (orta panel), SOM'un kapasiteyi ızgaraya birkaç biraz daha yoğun merkezle düzgünce dağıttığını gösterir. Baskın-sınıf paneli (sağ), latis üzerinde bir gradyan boyunca dizilmiş bitişik Düşük, Orta ve Yüksek sınıf bölgelerini, bazı hücreler $\geq 90\%$ saflığa ulaşacak şekilde ortaya koyar. Boş olmayan hücrelerin ortalama nöron-başına saflığı %67,5 olup, (neredeyse-tekdüze) sınıf dağılımı altında şaşırtıcı beklenen $\approx 35\%$ 'in çok üstündedir. SOM, böylece, orijinal 43-boyutlu özellik uzayında t-SNE haritasında görülen aynı gradyan-benzeri organizasyonu doğrular.

X. PctKids2Par ÜZERİNDE HİPOTEZ TESTİ (GÖREV 8)

Hipotez testi için PctKids2Par özelliği (iki-ebeveynli hanelerde yaşayan çocukların yüzdesi) seçilmiştir; çünkü en büyük Fisher Uzaklığına ve sınıf etiketiyle en büyük mutlak korelasyona sahiptir (Bölüm IV–V). Test edilecek hipotez, bu

TABLE 6. Düşük ve Yüksek suç sınıfları arasında PctKids2Par üzerinde Welch t-testi sonuçları.

Sınıf başına n	$\bar{x}_{\text{Düşük}} (\pm \text{s.s.})$	$\bar{x}_{\text{Yüksek}} (\pm \text{s.s.})$	t (p -değeri)
36	$0,759 \pm 0,130$	$0,463 \pm 0,147$	$9,01 (2,8 \times 10^{-13})$
64	$0,792 \pm 0,112$	$0,444 \pm 0,188$	$12,73 (7,3 \times 10^{-23})$
tümü	—	—	$39,28 (\approx 10^{-207})$

özelliğın ortalamasının *Düşük* ve *Yüksek* suç sınıfları arasında eşitliğidir:

$$H_0 : \mu_{\text{Düşük}} = \mu_{\text{Yüksek}}, \quad H_1 : \mu_{\text{Düşük}} \neq \mu_{\text{Yüksek}}.$$

Her sınıftan $n = 36$ ve $n = 64$ büyüklüğünde iki bağımsız rastgele örnek (yerine koymadan) çekilmiş ve iki-yönlü Welch t-testi (eşit varyans varsaymayan) uygulanmıştır. Sonuçlar Tablo 6’de özetlenmiştir.

Üç durumun tümünde (36, 64 büyüklüğünde örnekler ve tam sınıflar) p -değeri, $\alpha \in \{0,05, 0,01, 0,001\}$ gibi herhangi bir geleneksel anlamlılık düzeyinden onlarca büyüklük mertebesi daha küçüktür. Eşit ortalama sıfır hipotezi, dolayısıyla H_1 lehine ezici kanıtlarla reddedilir: PctKids2Par, Düşük-suç topluluklarında Yüksek-suç topluluklarına göre ortalama daha belirgin biçimde daha yüksektir (normalize ölçekte yaklaşık 0,79’a karşı 0,45; $[0, 1]$ ölçeğinde $\approx 0,33$ ’lük bir kayma). Beklendiği gibi, örnek büyüklüğünü 36’dan 64’e çıkarmak örnek ortalamalarını neredeyse değiştirmezken $|t|$ ’yi 9,01’den 12,73’e yükseltir; bu, aynı etki büyüklüğü için daha büyük örneğin daha yüksek istatistiksel gücünü gösterir. Tam-sınıf $t = 39,28$ değeri bu eğilimi mevcut verinin sınırına taşır.

XI. SONUÇ

Bu proje, UCI Communities and Crime veri setine eksiksiz bir keşifsel ve istatistiksel analiz boru hattı uygulamıştır. Etiket-kör, hiyerarşik-kümeleme tabanlı bir özellik seçimi 122 öngörücüyi redundant olmayan 43 özelliklik bir çalışma kümesine indirgemiş ve sürekli şiddet-suç oranı üç sınıfa ayrıştırılmıştır. Şu tutarlı tablo ortaya çıkar. İlk olarak, aile-yapısı ve sosyoekonomik temsilciler (PctKids2Par, PctIlleg, PctPopUnderPov, PctPersDenseHous, PctHousOwnOcc, medIncome) en güçlü tekil sınıf sinyalinin taşıyıcı; bu hem Pearson hem Spearman korelasyonu hem de özellik-başına Fisher Uzaklığı tarafından bağımsız olarak doğrulanır (Spearman-Pearson sıra uyumu 0,97); veri-güdümlü küme ayrıca aşırı kalabalıklaşmayı (PctPersDenseHous) elle-seçilmiş bir kümenin gözden kaçırabileceği bir üst korelasyon olarak su yüzüne çıkarır; buna karşılık pctUrban, agePct65up ve LandArea gibi demografik ve coğrafi değişkenler esasen sınıf-bilgisizdir. İkincisi, ayırt edici içerik çok az yönde yoğunlaşmıştır ama artık tek bir başat yönde değil: PC1 varyansın yalnızca %18,6’sını açıklar ve 0,56’lık bir Fisher Uzaklığı elde eder — bu, en iyi iki ham özellikten bile düşüktür — ikinci en büyük varyans bileşeni PC2 (%14,3) ise sınıf-ilgisizdir (Fisher 0,06). Eigenvalue ve Fisher Uza-

klığı, dolayısıyla, yalnızca zayıf biçimde ilişkilidir (tamen PC1 tarafından sürüklenen $r = 0,76$, $\rho = 0,49$): yüksek varyans yüksek ayırt ediciliği gerektirmez; bu nokta PC2 tarafından çarpıcı biçimde gösterilir. Üçüncüsü, LDA 2-B gömmesi sınıf ayrılabilirliğini ortaya koymada PCA 2-B gömmesini hem görsel hem nicel olarak açıkça geçer (silüet 0,127’ye karşı 0,049; 5-NN ÇD doğruluğu %65,9’a karşı %56,9); bunun nedeni tam olarak PCA’nın iki ekseninden birini sınıf-ilgisiz varyansa harcamak zorunda olması, denetimli LDA’nın ise olmamasıdır. Dördüncüsü, denimsiz kümeleme sınıf yapısının modal değil gradyan-benzeri olduğunu ortaya koyar: PCA düzleminde K-Means yalnızca mütevazı uyum elde eder (ARI 0,14), DBSCAN 233 gürültü noktasıyla tek baskın kümeye çöker (ARI 0,02) ve hem t-SNE hem SOM, üç sınıfın yumuşakça birbirine geçtiği sürekli bir manifold üretir; yine de SOM, şans düzeyinin çok üstünde, %67,5’lik bir ortalama nöron-başına sınıf saflığı elde eder. Son olarak, PctKids2Par üzerinde bir Welch t-testi, eşit sınıf ortalamaları sıfır hipotezini hem $n = 36$ ($t = 9,01$) hem $n = 64$ ($t = 12,73$) için aşırı anlamlılıkla reddederek önceki bölümlerin betimsel kanıtını biçimsel olarak doğrular.

Genel olarak, veri seti üç iyi-ayrılmış küme olarak değil, şiddet suçunun monotonik biçimde yükseldiği tek-boyutlu bir sosyoekonomik süreklilik olarak en iyi şekilde anlaşılır. Bu, denetimli bir doğrusal yöntemin (LDA) denimsiz PCA projeksiyonunu neden geçtiğini, yoğunluk-tabanlı kümelemenin neden başarısız olduğunu ve en güçlü tekil öngörücülerin neden salt demografik değil aile-yapısı ve yoksunluk göstergeleri olduğunu açıklar. Veri-güdümlü 43-özellik seçimi, hem elle düzenlemenin sübjektifliğini ortadan kaldırır hem de — PCA varyansı ile sınıf ayrılabilirliği arasındaki ayrışma ve aşırı kalabalıklaşmanın rolü gibi — daha küçük, elle-seçilmiş bir çalışma kümesinin gizleyeceği yapıyı açığa çıkarır.

APPENDIX. A

Tüm analiz boru hattını uygulayan Jupyter not defteri (Crime_Analysis.ipynb) ve üretilen tüm şekiller bu raporla birlikte sunulmaktadır. Orijinal veri seti UCI Makine Öğrenmesi Deposundan herkese açık olarak temin edilebilir [1].

REFERENCES

- [1] M. Redmond, “Communities and Crime Data Set,” UCI Machine Learning Repository, 2009. [Çevrimiçi]. Erişim: <https://archive.ics.uci.edu/ml/datasets/communities+and+crime>
- [2] G. Vettigli, “MiniSom: minimalistic and NumPy-based implementation of the Self Organizing Map,” 2018. [Çevrimiçi]. Erişim: <https://github.com/JustGlowing/minisom>
- [3] F. Pedregosa ve diğ., “Scikit-learn: Machine Learning in Python,” *Journal of Machine Learning Research*, c. 12, s. 2825–2830, 2011.
- [4] F. T. Liu, K. M. Ting, ve Z.-H. Zhou, “Isolation Forest,” *Proc. 2008 Eighth IEEE Int. Conf. on Data Mining (ICDM)*, 2008, s. 413–422.



Serkan Eren B.Sc. derecesini 2023 yılında Gebze Teknik Üniversitesi Elektronik Mühendisliği Bölümü'nden almış olup, hâlihazırda aynı üniversitede Yapay Zekâ alanında M.Sc. programını sürdürmektedir. FEV Türkiye bünyesinde Otomotiv Yazılım Mühendisi olarak görev yapmakta; Python tabanlı otomasyon, DevOps boru hatları ve gömülü yazılım entegrasyonu konularında çalışmalar yürütmektedir. Mesleki ilgi alanları derin öğrenme, akıllı sistemler için yazılım

mühendisliği ve otomasyon ile doğal dil işleme için veri-güdümlü uygulama geliştirmedir.

...